

Metin Gömmelerini (Text Embeddings) Anlamak ve Uygulamak

Yapay zeka sistemlerinde metinsel verinin semantik ve matematiksel olarak temsil edilmesi, modern dil modellerinin temel yapı taşıdır. Bu çalışma raporu, metin gömmelerinin (text embeddings) arkasındaki teoriyi, hesaplama ve öğrenme süreçlerini, pratik kullanım alanlarını detaylıca ele almaktadır.

1. Metin Gömme (Embedding) Nedir?

Metin gömme (text embedding), kelimeler, cümleler veya tüm paragraflar gibi metinsel verilerin, **semantik (anlamsal) olarak anlamlı bir uzayda** koordinatlar (vektörler) şeklinde temsil edilmesi yöntemidir. Anlamsal (semantics) ifadesi, bu koordinatların doğrudan metnin taşıdığı anlama işaret ettiğini gösterir. Metinler bu uzaya aktarıldığında, anlamsal açıdan benzer olan ifadeler birbirine çok yakın konumlarda (küçük mesafelerde) yer alırken, ilgisiz veya farklı konulardaki metinler uzayda birbirinden oldukça uzak noktalara düşer.


Semantik Uzay Örneği:

- 'Yüzme havuzunda kayıp flamingo bulundu'
- 'Sahilde sörf tahtasında görülen deniz samuru'
- 'Tekne gezisinin tadını çıkaran bebek panda'

gibi su ve hayvan temalı cümleler, gömme uzayında birbirine son derece yakın koordinatlara eşlenir. Buna karşın, 'Herkes tarafından sevilen yemek tırında kahvaltı' veya 'Yeni köri restoranı enfes' gibi yemek temalı cümleler bu gruptan çok daha uzak bir bölgede yer alır. Hayvan ve su içerikli cümlelerin kendi aralarındaki **ikili mesafeleri (pairwise distances)**, yemek içerikli cümlelerle olan mesafelerine göre çok daha düşüktür.

Şekil 1: Semantik Gömme Uzayında Noktaların Dağılımı ve Mesafe İlişkisi

Vektör Uzayında Semantik Yakınlık (Temsili 2D)



Şekil 1, benzer temalara sahip cümlelerin (örneğin hayvanlar ve su) gömme uzayında nasıl kümелendiğini ve farklı temalardaki gruplarla aralarındaki anlamsal mesafeyi görselleştirmektedir.

2. Metin Gömmeleri Nasıl Hesaplanır?

Metin gömmelerinin hesaplanmasında tarihsel süreçte basit ve statik yöntemlerden, günümüzün dinamik ve bağlama duyarlı transformer tabanlı sinir ağı mimarilerine doğru büyük bir evrim gerçekleşmiştir.

2.1 Geleneksel ve Modern Yaklaşımların Analizi

Geleneksel Yaklaşım (Kelime Bazlı Ortalama): Eski yöntemlerde, dilde en sık geçen kelimelerin sabit bir listesi tutulur ve her bir kelime için bağımsız gömme parametreleri eğitilirdi. Bir cümle gömülmek istendiğinde, cümledeki her bir kelimenin gömme vektörü alınır ve bunların **toplamı veya ortalaması** hesaplanırdı. Bu yöntemin en büyük kısıtlılığı, kelimelerin cümle içindeki **sıralamasını ve bağlamını tamamen göz ardı etmesidir**.

Modern Yaklaşım (Transformer Ağları): Günümüzde kullanılan gömme algoritmaları, çok daha gelişmiş bir yapıya sahiptir. Sabit vektör ortalamaları yerine, bir **Transformer Sinir Ağı** kullanılarak her kelimenin **bağlama duyarlı (context-aware)** temsili hesaplanır. Transformer ağı, bir kelimenin anlamını ve vektörünü belirlerken cümledeki diğer tüm kelimelerin varlığını ve konumunu da dikkate alır.

Bağlamsal Anlam Örneği ('Play' Kelimesi):

İngilizcedeki 'play' kelimesi, çocukların oyun oynamasını ifade eden '*kids playing*' bağlamında farklı bir anlam taşıırken, bir tiyatro oyununu belirten '*a play*' bağlamında tamamen farklı bir anlam ifade eder. Transformer modeli, kelimenin etrafındaki kelimeleri (bağlamı) analiz ederek bu iki farklı kullanım için **tamamen farklı vektör gömmeleri** hesaplayabilir.

Alt Kelime (Token) Seviyesinde Gömmeler ve Hata Toleransı

Modern büyük dil modelleri (LLM) metinleri doğrudan kelimeler yerine **token adı verilen alt kelime parçalarına** böler. Bu yaklaşımın en büyük avantajı, modelin daha önce eğitimde karşılaşmadığı yeni kelimelere (novel words) ve **yazım hatalarına (misspelled words)** karşı son derece dirençli olmasıdır. Örneğin, popüler bir bilimkurgu romanı başlığı olan ve bilerek 'universe' kelimesi yerine 'unverse' şeklinde yazılan '*the unverse, misspelled universe and everything*' ifadesi ele alınsın. Geleneksel yöntemlerde yanlış yazılan 'unverse' kelimesi sözlükte bulunamayacağı için anlamlı bir vektöre eşlenemezdi. Modern token tabanlı yöntemler ise bu kelimeyi alt parçalara ayırarak hataya rağmen oldukça başarılı ve **anlamlı bir cümle seviyesi gömmesi** hesaplayabilir. Bu sayede modele gönderilen her metin başarılı şekilde işlenir.

Tablo 1: Geleneksel ve Modern Gömme Teknolojilerinin Karşılaştırılması

Özellik	Geleneksel Yaklaşım	Modern Transformer Yaklaşımı
Hesaplama Yöntemi	Kelimelerin vektörlerinin basit toplamı veya ortalaması alınır.	Transformer ağı ile bağlama duyarlı kelime vektörleri üretilir.
Kelime Sıralaması	Sıralama bilgisi kaybolur, cümle yapısı dikkate alınmaz.	Kelimelerin cümledeki sırası ve pozisyonel ilişkileri tam olarak korunur.
Eşsesli / Çok Anlamlı	Farklı anlamlara gelen aynı kelimeye tek bir sabit vektör atanır.	Aynı kelimeye, bulunduğu bağlama göre farklı vektörler hesaplanır.
Yazım Hataları	Sözlük dışı (OOV) veya hatalı kelimelerde sistem başarısız olur.	Token/alt kelime yapısı sayesinde hatalı yazımlarda bile çalışır.

3. Gömmeler Nasıl Öğrenilir? (Contrastive Learning)

Transformer sinir ağlarının gömme oluşturma parametreleri, temelde **Contrastive Learning (Karşılaştırmalı Öğrenme)** adı verilen gelişmiş bir makine öğrenmesi tekniği ile eğitilir. Bu öğrenme süreci iki temel aşamadan oluşur:

1. Ön Eğitim (Pre-training): Transformer ağı öncelikle internetten veya çeşitli kaynaklardan toplanmış devasa miktardaki etiketlenmemiş (unlabeled) metin verisi üzerinde genel dil yapısını ve kelime ilişkilerini öğrenecek şekilde eğitilir (Büyük Dil Modellerinin standart eğitim yöntemi).

2. İnce Ayar (Fine-tuning): Bu aşamada, '**benzer cümle çiftleri**' içeren özel bir veri kümesi kullanılır. Algoritmanın temel amacı, anlamsal olarak benzer olduğu bilinen cümlelerin gömme vektörlerini uzayda birbirine **yakınlaştırmak**; benzer olmayan cümle çiftlerini ise birbirinden **uzaklaştırmaktır**.

Soru-Cevap Sistemlerinde Eğitim İlişkisi:

Eğer amacımız başarılı bir Soru-Cevap (Q&A) sistemi inşa etmekse, eğitim veri kümesinde her bir **soru ile o sorunun doğru cevabını** 'benzer cümle çifti' olarak tanımlarız. Bu sayede model, soru cümlesinin gömmesi ile cevap cümlesinin gömmesini uzayda birbirine yaklaştırır. Benzer olmayan cümleler ise genellikle rastgele seçilmiş cümle çiftleridir; çünkü rastgele iki cümlelerin anlamca yakın olma olasılığı düşüktür.

4. Çok Modlu (Multimodal) Gömmeler

Gömme teknolojisinin en heyecan verici ve yenilikçi alanlarından biri de **Çok Modlu (Multimodal) Gömmelerdir**. Bu sistemler, yalnızca metinleri değil, aynı zamanda **metinler ile görselleri (ve hatta ses verilerini) aynı ortak vektör uzayına** (örneğin 768 boyutlu bir uzaya) gömebilme yeteneğine sahiptir.

Görsel ve Metin Eşleme Örneği:

Eğer '*Portakal mevsimi geldi*' (*oranges are in season*) şeklinde bir metin cümlesini gömme uzayına gönderirsek ve aynı zamanda bir grup taze portakalın yer aldığı bir **resim görselini** çok modlu bir algoritma ile gömersek, model hem metni hem de görseli uzayda **birbirine son derece yakın koordinatlara** yerleştirecektir. Bu teknoloji, sistemlerin hem yazılı metinleri hem de resimleri aynı anda anlamlandırabilmesini sağlayarak görsel arama, resim alt yazısı oluşturma ve karmaşık çok modlu arama motorlarının kurulmasına olanak tanımaktadır.

5. Gömme Teknolojisinin Pratik Uygulama Alanları

Metin gömmeleri, karmaşık doğal dil işleme (NLP) görevlerini sadece vektörler arası mesafe (örneğin kosinüs benzerliği) hesaplamalarına indirgeyerek bilgisayarlar için son derece hızlı ve ölçeklenebilir hale getirir. En yaygın uygulamalar şunlardır:

- **Sınıflandırma (Classification):** Metinlerin anlamsal vektörlerine göre otomatik etiketlenmesi.
- **Kümeleme (Clustering):** Benzer içeriğe sahip binlerce belgenin ortak gruplarda (kümelerde) toplanması.
- **Aykırı Değer Tespiti (Outlier/Anomaly Detection):** Belirli bir gruptaki anlamsal akışa uymayan alakasız metinlerin tespit edilmesi.
- **Semantik Arama ve Soru-Cevap (Semantic Search & Q&A):** Klasik kelime eşleme yerine, sorunun asıl anlamsal içeriğine uygun doğru yanıtların veya belgelerin aranıp bulunması (RAG sistemlerinin kalbi).

-
- **Ürün Önerileri (Product Recommendations):** Kullanıcıların beğendiği veya satın aldığı ürün açıklamalarına (metinsel verilere) dayanarak anlamsal benzerliğe sahip yeni ürünlerin önerilmesi.

Sonuç

Metin gömmeleri, insan dilinin soyut ve karmaşık yapısını bilgisayarların işleyebileceği matematiksel bir dile dönüştürmektedir. Transformer ağları ve token tabanlı alt kelime yaklaşımları sayesinde, bu dönüşüm artık bağlama son derece duyarlı, imla hatalarına karşı toleranslı ve hatta resimlerle metinleri birleştirebilecek kadar esnek bir seviyeye ulaşmıştır. Bu çalışma raporu, bu güçlü teknolojinin teorik sınırlarını ve pratik kabiliyetlerini ortaya koymaktadır.