

İLERİ SEVİYE RAG SİSTEMLERİ VE DEĞERLENDİRME RAPORU

TruLens ve LlamaIndex Entegrasyonu ile RAG Üçlüsü (RAG Triad) Analizi

Kaynak: DeepLearning.AI | Hazırlayan: Gemini Notebook Çalışma Grubu

1. İLERİ SEVİYE RAG VE GÜNLÜK HAYAT ANALOJİLERİ

Geleneksel Büyük Dil Modelleri (LLM), yalnızca eğitim sırasında öğrendikleri verileri hatırlayarak yanıt üretirler. Bu durum, güncel olmayan veya özel veritabanlarında yer alan bilgilerin sorulması halinde sistemin yanlış veya uydurma bilgiler üretmesine (halüsinasyon) yol açar. Bilgiye Dayalı Erişim Destekli Nesil (RAG - Retrieval-Augmented Generation) mimarisi, LLM'lerin bu kısıtını ortadan kaldırarak, sorgu anında harici bir bilgi tabanından en alakalı verileri getirmeyi ve bu verilere dayalı yanıt üretmeyi hedefler.

Günlük Hayat Analojisi: Açık Kitap Sınavı (Open-Book Exam)

LLM'i tek başına sınava giren ve her şeyi ezberinden yazmak zorunda olan bir öğrenci gibi düşünün. Öğrenci bilmediği bir soru geldiğinde uydurmak (halüsinasyon) zorunda kalabilir. RAG ise bu sınavı '**Açık Kitap Sınavı**' haline getirir. Öğrencinin (LLM) önünde devasa bir kütüphane (Vektör Veritabanı) bulunur. Soru sorulduğunda, önce kütüphaneden en alakalı birkaç sayfa hızla bulunur (Erişim - Retrieval), ardından öğrenci bu sayfaları okuyarak tam ve doğru yanıtı sentezler (Nesil - Generation). Böylece uydurma riski minimize edilir ve yanıtlar doğrulanabilir hale gelir.

Ancak temel RAG mimarilerinde büyük bir sorun vardır: Belgeler büyük parçalara (chunk) bölündüğünde, LLM'e aktarılan metnin içinde gereksiz birçok bilgi bulunur ve bu durum yanıt kalitesini düşürür. Bu sorunu çözmek için geliştirilen en güçlü yöntemlerden biri **Cümle Penceresi Erişimi (Sentence-Window Retrieval)** tekniğidir. Bu yöntemde belgeler tek tek cümleler halinde indekslenir. Sorgu anında en alakalı cümle bulunur, ancak LLM'e sadece o cümle değil, onun öncesindeki ve sonrasındaki komşu cümleleri içeren bir 'pencere' gönderilir.

Günlük Hayat Analojisi: Büyüteç ve Çevre Bağlamı

Geleneksel yöntemlerle koca bir paragrafı (büyük bir chunk) getirmek, karanlık bir odadaki eşyayı bulmak için dev bir projektör yakıp her şeyi birbirine karıştırmaya benzer. **Cümle Penceresi Erişimi** ise hedefe odaklı bir büyüteç gibidir. Aradığımız anahtar kelimeyi veya cümleyi büyüteçle net bir şekilde buluruz. Ancak büyüteçle sadece o cümleye bakarsak, 'O bunu yaptı' gibi ifadelerdeki 'O' zamirinin kime ait olduğunu (bağlamı) anlayamayız. Bu yüzden büyüteçle odaklandığımız cümlenin hemen yanındaki 3 cümle öncesini ve 3 cümle sonrasını da görüş alanımıza dahil ederiz. Böylece LLM, gereksiz sayfa kalabalığı altında ezilmeden tam olarak ihtiyacı olan geniş bağlama sahip olur.

2. DEĞERLENDİRME KRİTERİ: RAG ÜÇLÜSÜ (THE RAG TRIAD)

Bir RAG uygulamasının kalitesini ölçmek zordur çünkü sistem hem bir 'erişim' (retrieval) hem de bir 'üretim' (generation) mekanizması barındırır. TruLens çerçevesi, RAG mimarisinin üç temel adımını ölçen ve

halüsinasyonları kesin olarak tespit eden **RAG Üçlüsü (RAG Triad)** metodolojisini sunar. RAG Üçlüsü, LLM tabanlı uygulamaların doğruluğunu, dürüstlüğü ve yararlılığını ölçmek için tasarlanmış üç bağımsız metriktir.

Günlük Hayat Analogisi: Üç Hakemli Jüri


Açık kitap sınavına giren öğrencimizi değerlendiren 3 hakemli bir jüri hayal edin:

- 1. Araştırma Hakemi (Context Relevance):** Öğrencinin soruyu cevaplamak için kütüphaneden getirdiği kitap sayfaları gerçekten soruyla alakalı mı? Yoksa coğrafya sorusuna tarih kitabı mı getirdi?
- 2. Bilgi Doğrulama Hakemi (Groundedness):** Öğrencinin yazdığı cevap, getirdiği kitap sayfalarında yazıyor mu? Kitapta yazmayan bir şeyi kendi kafasından mı ekledi? (Halüsinasyon tespiti)
- 3. Odaklanma Hakemi (Answer Relevance):** Öğrencinin yazdığı cevap, hocanın sorduğu soruya gerçekten cevap veriyor mu? Soruyla doğrudan ilgili mi, yoksa konuyu saptırmış mı?

Metrik Adı	İlgili RAG Aşaması	Girdi / Çıktı İlişkisi	Değerlendirme Kriteri / Amaç
Context Relevance (Bağlam Uygunluğu)	Retrieval (Erişim)	Sorgu (Query) <-> Bağlam (Context)	Getirilen bağlam parçalarının kullanıcı sorgusuyla ne kadar alakalı olduğunu ölçer. Gereksiz gürültüyü ve maliyeti azaltmayı amaçlar.
Groundedness (Temellilik / Gerçeklik)	Generation (Nesil)	Bağlam (Context) <-> Yanıt (Response)	LLM yanıtındaki her bir cümle için getirilen kaynak bağlam tarafından desteklenip desteklenmediğini ölçer. Doğrudan halüsinasyonu yakalar.
Answer Relevance (Yanıt Uygunluğu)	Generation (Nesil)	Sorgu (Query) <-> Yanıt (Response)	Üretilen nihai yanıtın, kullanıcının sorduğu soruya ne kadar doğrudan ve tatmin edici bir cevap verdiğini ölçer.

Temel RAG ve Cümle Penceresi RAG Karşılaştırması

Temel RAG ve İleri RAG Sistemlerinin Karşılaştırmalı Metrik Analizi



Şekil 1: TruLens test sonuçlarına dayanan temel RAG ile Cümle Penceresi RAG performans karşılaştırması.

3. ADIM ADIM PYTHON UYGULAMA REHBERİ

Bu bölümde, DeepLearning.AI dersinde gösterilen LlamaIndex ve TruLens entegrasyonu kodlarının tamamı mantıksal adımlarla açıklanmıştır. Kod örneklerinde OpenAI GPT-3.5 Turbo modeli ve BGE-Small-EN-v1.5 gömme (embedding) modeli kullanılmaktadır.

Adım 1: OpenAI API Anahtarı ve TruLens Veritabanı Kurulumu

İlk olarak, hem RAG sisteminin çalışması hem de TruLens'in LLM tabanlı değerlendirmeleri gerçekleştirmesi için OpenAI API anahtarı tanımlanır. Ardından, değerlendirme sonuçlarını, logları ve metrikleri kaydetmek için yerel TruLens veritabanı kurulur.

```
import os
from truelens_eval import Tru

# OpenAI API anahtarının tanımlanması
os.environ["OPENAI_API_KEY"] = "your_openai_api_key_here"

# TruLens veritabanı nesnesinin oluşturulması ve sıfırlanması
tru = Tru()
tru.reset_database() # Her yeni çalıştırmada temiz veritabanı ile başlamak için
```

Adım 2: LlamaIndex ile Belge Yükleme ve Cümle Penceresi İndeksi Oluşturma

Andrew Ng tarafından yazılan 'How to Build a Career in AI' PDF belgesi yüklenir. Varsayılan olarak sayfa sayfa bölünen metin, bütünsel bir bağlam sağlamak amacıyla tek bir büyük döküman halinde birleştirilir. Cümle Penceresi (Sentence Window) mekanizması kurularak hedeflenen cümlenin 3 cümle öncesi ve sonrasını içeren bir arama penceresi tanımlanır.

```
from llama_index import SimpleDirectoryReader, Document, ServiceContext, VectorStoreIndex
from llama_index.llms import OpenAI
from llama_index.node_parser import SentenceWindowNodeParser

# 1. Belgenin dizinden okunması
reader = SimpleDirectoryReader(input_files=["how_to_build_a_career_in_ai.pdf"])
documents = reader.load_data()

# 2. Tüm sayfaların tek bir döküman olarak birleştirilmesi
document = Document(text="\n\n".join([doc.text for doc in documents]))

# 3. Cümle penceresi bölücüsünün tanımlanması (Önceki/Sonraki 3 cümle)
node_parser = SentenceWindowNodeParser.from_defaults(
    window_size=3,
    window_metadata_key="window",
    original_text_metadata_key="original_text"
)

# 4. Dil modeli ve Gömme (Embedding) modeli ayarları
llm = OpenAI(model="gpt-3.5-turbo", temperature=0.1)
sentence_context = ServiceContext.from_defaults(
    llm=llm,
    embed_model="local:BAAI/bge-small-en-v1.5", # BGE Small v1.5 entegrasyonu
    node_parser=node_parser
)

# 5. Vektör indeksinin ve Sorgu Motorunun (Query Engine) oluşturulması
sentence_index = VectorStoreIndex.from_documents([document], service_context=sentence_context)
query_engine = sentence_index.as_query_engine(similarity_top_k=2)
```

Adım 3: TruLens ile Geri Bildirim Fonksiyonlarının (Feedback Functions) Tanımlanması

TruLens, RAG Üçlüsü'nü oluşturmak için değerlendirici olarak yine OpenAI GPT-3.5 modelini kullanır. Burada her bir metrik, karar süreçlerinin şeffaf olması amacıyla zincirleme düşünce gerekçesiyle (Chain-of-Thought Reasoning) birlikte kurulur.

```
from truelens_eval import Feedback, select_context
from truelens_eval.feedback.provider import OpenAI as TruLensOpenAI
from truelens_eval.feedback import Groundedness
import numpy as np

# OpenAI Değerlendirme Sağlayıcısının başlatılması
provider = TruLensOpenAI(model_engine="gpt-3.5-turbo")

# --- 1. ANSWER RELEVANCE (Yanıt Uygunluğu) ---
f_answer_relevance = (
    Feedback(provider.relevance_with_cot_reasoning, name="Answer Relevance")
    .on_input_output()
)

# --- 2. CONTEXT RELEVANCE (Bağlam Uygunluğu) ---
context_selection = select_context(query_engine) # Geri getirilen düğümlere işaretçi
f_context_relevance = (
    Feedback(provider.qs_relevance_with_cot_reasoning, name="Context Relevance")
    .on_input()
    .on(context_selection)
    .aggregate(np.mean) # Tüm parçaların ortalamasını alır
)

# --- 3. GROUNDEDNESS (Temellilik / Gerçeklik) ---
grounded = Groundedness(groundedness_provider=provider)
f_groundness = (
    Feedback(grounded.groundedness_measure_with_cot_reasoning, name="Groundedness")
    .on(context_selection)
    .on_output()
    .aggregate(grounded.blended_groundness_measure)
)
```

Adım 4: TruRecorder Kaydedicinin Tanımlanması ve Sorguların Çalıştırılması

LlamaIndex ile TruLens'i birbirine bağlayan `TruLlama` sınıfı kullanılarak bir `TruRecorder` nesnesi oluşturulur. Bu nesne, sorgu anında tüm girdileri, çıktıları, getirilen bağlamları ve hesaplanan metrik puanlarını otomatik olarak veritabanına kaydeder.

```
from truelens_eval import TruLlama

# LlamaIndex sorgu motorunu TruLens kaydedici ile sarmallıyoruz
tru_recorder = TruLlama(
    query_engine,
    app_id="Sentence_Window_RAG_App",
    feedbacks=[f_answer_relevance, f_context_relevance, f_groundedness]
)

# Değerlendirme için test sorularının tanımlanması
eval_questions = [
    "What are the keys to building a career in AI?",
    "How can I be successful in the AI?"
]

# Soruların kaydedici bağlamında (with context) çalıştırılması
for question in eval_questions:
    with tru_recorder as recording:
        response = query_engine.query(question)
```

Adım 5: Gözlenebilirlik, Dashboard ve Metriklerin Alınması

Çalıştırma sonrasında kayıtlı veriler doğrudan veri çerçevesi (DataFrame) olarak alınabilir veya yerel bir Streamlit arayüzü başlatılarak tüm sistem performansı (gecikme, token maliyeti, kararlar) görsel olarak analiz edilebilir.

```
# 1. Logları ve Metrikleri DataFrame olarak okuma
records, feedback = tru.get_records_and_feedback(app_ids=[])

# 2. Ortalama skorları gösteren Lider Tablosunu (Leaderboard) çağırma
leaderboard = tru.get_leaderboard(app_ids=[])

# 3. Yerel Streamlit Portalı Başlatma (Tarayıcı üzerinden görsel takip)
tru.run_dashboard()
```

Geleneksel Değerlendirme Yöntemlerine (ROUGE, BLEU) Yönelik Eleştiri

İleri seviye RAG sistemlerinde ROUGE ve BLEU gibi geleneksel NLP değerlendirme metriklerinin kullanılması önemli yetersizlikler barındırır. Bu metrikler tamamen **sentaktiktir (kelime bazlı eşleşme)**. Örneğin, 'banka' kelimesinin nehir kenarını mı yoksa finansal kuruluşu mu kastettiğini ayırt edemezler. Ayrıca aynı anlamı taşıyan fakat farklı kelimelerle kurulan cümlelere (örneğin eş anlamlı kelimeler kullanıldığında) düşük skor verirler. TruLens'in sunduğu LLM-as-a-Judge yaklaşımı ise **semantik bağlamı (anlamsal bütünlüğü)** değerlendirir, böylece kelimeler birebir eşleşmese bile anlamın doğruluğunu ve temelliliğini %80-85 oranında insan hakem tutarlılığıyla ölçebilir.

4. TRULENS İLE BAŞARI VE BAŞARISIZLIK SENARYO ANALİZLERİ

TruLens paneli üzerinden yapılan incelemelerde, RAG sisteminin ürettiği yanıtların güvenilirliği ve karşılaşılan somut başarısızlık senaryoları şu şekilde analiz edilmiştir:

Senaryo A (Başarılı Örnek - %100 Doğruluk / Groundedness: 1.0)

Soru: 'What is the first step to becoming good at AI?' (AI alanında iyi olmanın ilk adımı nedir?)

Sistem Yanıtı: 'is to learn foundational technical skills.' (temel teknik becerileri öğrenmektir)

Değerlendirme: Bu yanıt TruLens tarafından yapılan değerlendirmede **Groundedness: 1.0 (Tam Puan)** almıştır. Çünkü sistemin veritabanından çektiği Andrew Ng'in kariyer rehberi belgesinde, yapay zekada başarılı olabilmek için temel matematik, kodlama ve makine öğrenmesi temellerinin alınması gerektiği net bir şekilde yazmaktadır. Yanıtın her bir kelimesi kaynak belgedeki bilgilerle birebir örtüşmektedir ve uydurma bilgi barındırmamaktadır.

Senaryo B (Başarısızlık Örneği - Düşük Temellilik ve Halüsinasyon / Groundedness: 0.5)

Soru: 'How can altruism be beneficial in building a career?' (Diğerkâmlık/Altrüizm kariyer yapmada nasıl faydalı olabilir?)

Sistem Yanıtı: Sistem, diğerkâmlığın iş ağını genişleteceğini belirttikten sonra ek olarak: 'Additionally, practicing altruism can contribute to personal fulfillment and a sense of purpose, which can enhance motivation and overall well-being, ultimately benefiting one's career success.' (Ayrıca diğerkâmlık kişisel doyum ve amaç duygusu sağlayarak motivasyonu ve esenliği artırır, bu da nihayetinde kariyer başarısına katkıda bulunur) ifadesini eklemiştir.

Değerlendirme: Bu cümle kulağa son derece mantıklı ve doğru gelse de, **Groundedness puanı 0.5'e (Çok Düşük) düşmüştür.** Çünkü Andrew Ng'in rehber belgesinde diğerkâmlığın 'kişisel doyum sağladığı veya genel esenliği artırarak kariyere dolaylı etki ettiği' yönünde hiçbir bilgi **bulunmamaktadır**. LLM, kendi ön eğitim verilerinden gelen genel bilgileri kullanarak belgedeki boşlukları uydurma (hallucination) bilgilerle doldurmuştur. TruLens bu uydurmayı başarıyla yakalamış ve sistemi cezalandırmıştır.